

# 基于 LSTM-AKF 的装甲板中心点未来轨迹预测方法

作者姓名待补充

(单位名称待补充, 城市 邮编待补充)

摘要: 针对机器人视觉瞄准场景中装甲板中心点观测序列存在抖动、短时漏检与未来运动不确定性较强的问题, 提出一种融合自适应卡尔曼滤波(AKF)与长短期记忆网络(LSTM)的未来中心点预测方法。该方法首先由 YOLO 检测器提取当前最优打击目标中心点, 利用 AKF 对历史轨迹进行去噪、补位和基线外推; 随后以历史归一化坐标序列为输入, 通过 LSTM 学习非线性运动残差, 并采用门控机制融合神经网络预测与 AKF 基线结果。基于项目视频数据构建 7,393 个样本, 并采用 segment 级划分进行训练和验证。实验结果表明, LSTM-AKF 在多种预测范围上取得最佳综合表现, 平均 DE 为 0.018794, 平均命中率为 68.8%; 在 15 帧序列预测中 DE 为 0.01744, 能够在保持较低推理开销的同时提升未来轨迹预测稳定性。

关键词: 装甲板中心点; 轨迹预测; LSTM; 自适应卡尔曼滤波; 门控融合

中图分类号: TP391.41 文献标志码: A

## Future trajectory prediction of armor-plate center points based on LSTM-AKF

Author names to be completed

(Affiliation to be completed, City, Postcode, China)

Abstract: A future armor-plate center prediction method combining adaptive Kalman filtering (AKF) and long short-term memory network (LSTM) is proposed to reduce observation jitter, short-term missed detections, and motion uncertainty in robot vision aiming. The YOLO detector first extracts the center of the current target, and AKF is used for trajectory smoothing, gap filling, and baseline extrapolation. Then an LSTM learns nonlinear motion residuals from historical normalized coordinates, while a gated fusion module combines the neural prediction with the AKF baseline. Experiments on 7,393 generated samples show that LSTM-AKF achieves the best overall ranking with an average DE of 0.018794 and an average hit rate of 68.8%, demonstrating stable multi-horizon prediction with low inference cost.

Keywords: armor plate center; trajectory prediction; LSTM; adaptive Kalman filter; gated fusion

## 0 引言

在 RoboMaster 等机器人对抗场景中, 装甲板中心点的未来位置直接影响云台提前量计算、弹道补偿和目标跟踪稳定性。由于视觉检测结果受到运动模糊、遮挡、光照变化及检测框抖动影响, 直接利用单帧检测点进行未来外推容易产生较大误差。因此, 如何在有限历史观测下同时利用物理运动先验和时序学习能力, 是提升短时预测精度的关键问题。

传统卡尔曼滤波方法具有计算量低、状态可解释性强的优点, 但难以刻画装甲板在急停、转向和非匀加速运动中的非线性残差。LSTM 能从历史序列中学习运动

模式, 但在漏检和短轨迹条件下容易受到噪声传播影响。本文采用 AKF 生成平滑基线, 并以 LSTM 学习相对基线的残差, 再通过门控融合动态调节两类信息的权重, 从而兼顾鲁棒性与表达能力。

## 1 数据集构建与任务定义

### 1.1 检测轨迹与样本生成

项目默认从 data/video/ 目录读取原始视频，由 YOLO 检测器逐帧输出目标框，并选取当前最优打击目标的中心点作为观测。中心点统一转换为归一化坐标，随后进入 AKF 状态估计模块。连续漏检不超过 5 帧时由滤波器进行短时补位，超过阈值则切换为新的轨迹段，避免跨段拼接带来的标签污染。

表 1 数据集与模型配置统计

Table 1 Statistics of dataset and model configuration

| 项目   | 数值      | 项目    | 数值     |
|------|---------|-------|--------|
| 总样本数 | 7,393   | 轨迹组数  | 89     |
| 训练样本 | 5,915   | 验证样本  | 1,478  |
| 划分方式 | segment | 模型参数量 | 92,221 |

样本采用滑动窗口构建，历史输入长度为 5 到 15 帧，预测目标为未来 1 到 15 帧的归一化中心点序列。数据划分默认采用 segment 级策略，使同一连续轨迹段不会同时出现在训练集和验证集中，从而降低同源轨迹泄漏对评估结果的影响。

### 1.2 评价指标

本文采用 DE、MSE、RMSE、MAE、Hit Rate 与推理时间评估模型性能。DE 表示预测点与真实点之间的欧氏距离，Hit Rate 按照 DE 不超过 0.02 的规则统计命中比例。单帧评估关注第 8 帧和第 15 帧的未来点，序列评估关注前 8 帧和前 15 帧的整体轨迹误差。

## 2 LSTM-AKF 预测模型




图 1 LSTM-AKF 模型结构

Fig. 1 Structure of the LSTM-AKF model

### 2.1 AKF 状态估计与基线外推

AKF 模块维护  $[cx, cy, vx, vy, ax, ay]$  状态向量，其中  $cx$  与  $cy$  为归一化中心点坐标， $vx$  与  $vy$  表示速度， $ax$  与  $ay$  表示加速度。滤波器根据当前检测点自适应更新状态协方差，并在短时漏检时输出平滑补位结果。对未来窗口，AKF 按状态转移模型生成基线轨迹，为后续 LSTM 残差学习提供物理先验。

### 2.2 LSTM 残差预测与门控融合

LSTM 分支读取历史  $xy$  序列并输出未来多步残差预测。融合层根据历史运动状态生成门控权重，使模型在平稳运动时更多依赖 AKF 基线，在出现非线性机动时提高 LSTM 残差贡献。该结构避免了固定相加带来的误差放大问题，并保留了滤波外推的稳定性。




图 2 中心点预测流程

Fig. 2 Pipeline of center-point prediction

## 3 实验设置

### 3.1 训练配置

主模型训练采用早停策略，最优轮次为第 90 轮，停止轮次为第 110 轮，最佳验证损失为 0.001225。在当前 exp001 结果中，验证 ADE 为 0.01744，FDE 为 0.02756。训练脚本统一记录 loss、ADE 与 FDE，并将最优权重保存至 outputs/exp001/checkpoints/best.pt。

### 3.2 对比模型

为验证门控 LSTM-AKF 的有效性，实验固定比较 LSTM-AKF、AKF-only、LSTM-only、ANN、SVR、AR、DT 与 KNN。其中 AKF-only 直接采用滤波基线，LSTM-only 去除 AKF 融合分支，传统机器学习模型使用相同历史窗口展开后的特征进行训练。所有模型在相同验证集上输出统一指标，以保证横向对比的一致性。

## 4 实验结果与分析

表 2 模型综合性能排序

Table 2 Overall ranking of compared models

| 排名 | 模型        | 平均 DE   | 命中率/% | 时间/ms |
|----|-----------|---------|-------|-------|
| 1  | LSTM-AKF  | 0.01879 | 68.8  | 0.056 |
| 2  | LSTM-only | 0.01918 | 67.9  | 0.038 |
| 3  | AR        | 0.01967 | 67.4  | 0.001 |
| 4  | ANN       | 0.02035 | 67.2  | 0.027 |
| 5  | SVR       | 0.02098 | 68.2  | 5.905 |
| 6  | KNN       | 0.02906 | 53.3  | 0.072 |

综合排序结果显示, LSTM-AKF 在四个评估范围中取得三项第一, 平均 DE 低于 LSTM-only、AR 与 ANN。AKF-only 在长预测范围下误差显著上升, 说明仅依赖匀加速外推难以覆盖复杂机动; 而 LSTM-only 虽在第 15 帧单点上接近主模型, 但序列预测稳定性略弱于 LSTM-AKF。

表 3 LSTM-AKF 在不同预测范围下的结果  
Table 3 Results of LSTM-AKF under different horizons

| 范围    | DE      | RMSE    | MAE     | 命中率/% |
|-------|---------|---------|---------|-------|
| 单帧 8  | 0.01848 | 0.01307 | 0.01061 | 68.5  |
| 单帧 15 | 0.02756 | 0.01949 | 0.01582 | 51.8  |
| 序列 8  | 0.01169 | 0.00939 | 0.00672 | 83.5  |
| 序列 15 | 0.01744 | 0.01432 | 0.01002 | 71.5  |

从单帧和序列结果看, LSTM-AKF 在第 8 帧预测中具有较高命中率, 在第 15 帧预测中仍保持可控误差。这表明 AKF 基线能够抑制观测噪声, LSTM 残差能够补偿非线性趋势, 两者通过门控融合形成互补。




图 3 15 帧序列预测指标对比  
Fig. 3 Metric comparison for 15-frame sequence prediction




图 4 真实画面中的未来轨迹预测示例  
Fig. 4 Example of future trajectory prediction in a real frame

可视化结果进一步说明, 模型输出不仅需要贴近未来中心点, 还需要保持轨迹方向和曲率的一致性。当目标轨迹短时平滑时, AKF 基线可提供稳定外推; 当目标运动趋势发生变化时, LSTM 分支对残差的修正能够降低末端漂移。

## 5 结束语

本文围绕装甲板中心点未来轨迹预测任务, 构建了从视频检测、轨迹分段、滑窗切样、模型训练到多模型对比的完整流程, 并采用近似期刊论文的双栏排版方式整理实验方法与结果。实验表明, LSTM-AKF 在短时和中期预测范围上均具有较好的综合性能。后续工作可进一步引入速度、加速度或目标姿态等显式特征, 并在更多实战视频和不同相机视角下验证模型的泛化能力。

## 参考文献:

- [1] Kalman R E. A new approach to linear filtering and prediction problems [J]. Journal of Basic Engineering, 1960, 82(1): 35-45.
- [2] Hochreiter S, Schmidhuber J. Long short-term memory [J]. Neural Computation, 1997, 9(8): 1735-1780.
- [3] Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking [C]. //IEEE International Conference on Image Processing. 2016: 3464-3468.
- [4] 李德毅, 杜鹞. 不确定性人工智能 [M]. 北京: 国防工业出版社, 2005.
- [5] LSTM-AKF 项目组. 模型结构设计与数据集构建方案 [R]. 2026.